

Sistema de Clasificación Automatizada de Frutas mediante Red de Carpenter-Grossberg (ART1)

Trabajo Final Integrador
Entrega Parcial de Mitad de Año



Materia: Inteligencia Artificial



Docentes: Dra. Daniela López De Luise
Ing. Alejandro Pérez

Grupo 2 — Integrantes:

- Barbera, Mateo
- Carballo, Tobías
- Dacuy, Santino
- Etchegoyen, Nicolás
- Leiva, Osvaldo



SISTEMA DE CLASIFICACIÓN AUTOMATIZADA DE FRUTAS MEDIANTE RED DE CARPENTER-GROSSBERG (ART1)

1. Definición del Problema y Justificación

1.1 Problema

Clasificación automatizada de frutas y control de calidad basado en estándares de exportación, mediante procesamiento binarizado de características físicas y ópticas.

1.2 Justificación

Se seleccionó la arquitectura de **Carpenter-Grossberg (ART1)** debido a su capacidad para resolver el **Dilema de Estabilidad-Plasticidad**. A diferencia de otros, esta red permite al sistema aprender nuevos criterios de fallas o nuevas variedades de frutas (*plasticidad*) en tiempo real, sin degradar ni olvidar los patrones de clasificación previamente establecidos (*estabilidad*).

El sistema no actúa como un filtro estático, sino como un **clasificador adaptativo** que identifica combinaciones complejas de características morfológicas y de superficie. (Morfológicas = la forma física de la fruta), adecuado para líneas de producción dinámicas donde los criterios de calidad pueden actualizarse sin reentrenar desde cero.

A. ¿Por qué no el Perceptrón (Simple o Multicapa)? El Perceptrón utiliza aprendizaje supervisado, lo que requiere que un operador etiquete de antemano grandes volúmenes de muestras para entrenar la red. Además, si las condiciones cambian y aparece un defecto nuevo en la cáscara, el Perceptrón no puede adaptarse sin reentrenamiento completo. **ART1 es no supervisada**: descubre los patrones y agrupa las frutas por sí sola, sin necesidad de datos etiquetados previos.

B. ¿Por qué no la Red de Hamming? La red de Hamming requiere que el número de clases esté fijado de antemano en su estructura. Si se configura para 3 clases, está obligada a forzar cualquier entrada en una de ellas, incluso si se trata de una fruta completamente distinta o desconocida. **ART1**, en cambio, **tiene la capacidad de crear un grupo nuevo** cuando detecta algo que no se parece a ningún patrón conocido.

C. ¿Por qué no la Red de Hopfield? La red de Hopfield funciona como memoria asociativa para recuperar patrones ruidosos, pero su capacidad de almacenamiento es muy limitada: se satura y genera patrones falsos cuando se supera el 15% de su capacidad máxima. No está diseñada para clasificación industrial masiva.

1.3 El argumento central: El Dilema de Estabilidad-Plasticidad

Las redes neuronales tradicionales sufren de **olvido catastrófico**: si una red ya aprendió a clasificar manzanas y se la entrena con nuevos datos, puede degradar o borrar lo que aprendió anteriormente.

ART1 resuelve este dilema mediante dos capacidades complementarias:

- **Plasticidad**: capacidad de aprender nuevos patrones en tiempo real.
- **Estabilidad**: capacidad de retener el conocimiento previo sin que se corrompa.

Cuando ingresa una fruta con características nunca antes vistas, la red crea una categoría nueva sin modificar los pesos de los grupos ya consolidados. Esto es ideal para una línea de producción que opera de forma continua y no puede detenerse para reentrenar toda la red desde cero ante cada cambio de lote o variedad.

2.A Diseño de los Sets de Datos y Proceso de Binarización

2.1 Justificación de la Binarización

La red clásica ART1 opera estrictamente con **vectores binarios (0 y 1)**, realizando operaciones lógicas AND entre vectores. La bibliografía advierte que cuando se dispone de cantidades analógicas (como los valores continuos de una escala de grises), se debe resolver un **problema de representación fundamental** convirtiendo esos valores a binario mediante umbrales de corte.

Esta decisión tiene además una justificación práctica: en automatización industrial, procesar imágenes en alta resolución a color es computacionalmente costoso. Un análisis basado en escala de grises binarizada simula un **sensor industrial de bajo costo y alta velocidad**, permitiendo tomar decisiones en milisegundos cuando la fruta pasa por la cinta transportadora.

2.2 Datasets

Se desarrollarán **dos datasets independientes** de al menos 50 registros y 5 variables binarias cada uno, en formato CSV.

Dataset 1: Clasificación Morfológica Automática (Variedades)

Objetivo: Agrupar de manera autónoma diferentes tipos de frutos ingresados a la planta (Cítricos, Tropicales, de Carozo) para su correcto direccionamiento logístico.

Variable	Nombre en CSV	Descripción	Valor 1	Valor 0
1	es_esferica	Relación de aspecto geométrico cercana a 1	Esférica	Alargada
2	cascara_rugosa	Filtrado de alta frecuencia detecta rugosidad	Rugosa (ej. naranja)	Lisa (ej. manzana/uva)
3	tiene_tallo	Segmentación detecta apéndice leñoso	Presente	Ausente
4	densidad_alta	Relación peso/volumen estimada alta	Alta	Baja / hueca
5	pigmentacion_oscura	Niveles promedio de gris reflejan absorción por coloración intensa	Oscura	Clara

Dataset 2: Control de Calidad en Línea de Producción (Manzanas)

Objetivo: Agrupar de forma no supervisada las muestras en tres categorías comerciales: *Premium*, *Comercial* y *Descarte*.

Variable	Nombre en CSV	Descripción	Valor 1	Valor 0
1	es_grande	Diámetro supera umbral estándar	> 7 cm	≤ 7 cm
2	es_pesada	Peso supera umbral mínimo	> 150 g	≤ 150 g
3	textura_firme	Rigidez óptima al tacto	Firme	Ablandada
4	sin_defectos_superficie	Análisis de histograma en escala de grises sin manchas oscuras	Sin anomalías	Con golpes / Hongos
5	color_homogeneo	Maduración cubre porcentaje requerido por contrato	Homogéneo	Verde / Pasada

2.B Limpieza de Datos y Preprocesamiento

2.3 Objetivo principal: eliminación del ruido

La limpieza consistirá en aislar la fruta y remover completamente el fondo de la imagen antes de analizarla.

La red ART1 es extremadamente sensible al ruido. Si el fondo de la imagen no es eliminado (sombras, superficie de la mesa, variaciones de iluminación), la red lo interpretará como parte del patrón de la fruta. Esto provoca que, ante un umbral de vigilancia alto, la operación lógica AND degrade el patrón original almacenado y la red comience a crear categorías nuevas sin control por cada variación mínima detectada, hasta agotar todos los nodos disponibles. Una entrada ruidosa no produce una clasificación incorrecta: produce una proliferación descontrolada de clústeres.

2.4 Método: algoritmo preprocesador

Para la limpieza y extracción de características se utilizará un **módulo preprocesador** implementado en Python (mediante librerías como OpenCV) que operará de forma previa e independiente a CarGross.py.

La bibliografía respalda este enfoque al señalar que los sistemas basados en redes neuronales influyen en la práctica **algoritmos preprocesadores de propósito especial** para preparar la información antes de que llegue a la red. El preprocesador tendrá las siguientes responsabilidades:


1. Segmentar la fruta y eliminar el fondo de la imagen.
2. Convertir la imagen limpia a escala de grises.
3. Extraer las características morfológicas y ópticas relevantes.

2.5 Conversión a binario: solución al problema de representación

Una vez obtenida la imagen limpia en escala de grises, **no se entregará ese valor analógico a la red**. Se aplicarán umbrales de corte para convertir cada característica a un valor estrictamente binario (0 o 1).

Este paso resuelve lo que la bibliografía denomina el **problema de representación fundamental**: la red ART1, al igual que otras de su taxonomía, opera exclusivamente con entradas binarias. El autor advierte explícitamente que cuando se dispone de cantidades analógicas como una escala de grises continua, se debe resolver este problema de representación antes de que los datos ingresen a la red. La aplicación de umbrales de corte es exactamente la solución implementada en este proyecto.

El flujo completo queda definido de la siguiente manera:



3. Métricas de Evaluación del Éxito

El éxito del modelo CarGross.py se determinará midiendo la **cantidad y estabilidad de los clústeres formados** en función del umbral de vigilancia (ρ), de acuerdo al siguiente criterio:

Resultado fallido: Si el dataset contiene 3 tipos de frutas reales y la red genera 15 o más clústeres distintos, significa que el umbral es demasiado alto y la red está reaccionando al ruido en lugar de a los patrones reales.

Resultado exitoso: La ejecución del modelo se valida como correcta cuando, tras ajustar iterativamente ρ , el algoritmo estabiliza su salida y agrupa los datos en un número de clústeres coherente con las categorías reales del dataset, sin generar clústeres espurios.

Se evaluarán específicamente:

- Convergencia matemática limpia hacia los grupos lógicos esperados.
- Ausencia de proliferación infinita de categorías ante variaciones mínimas en los datos.
- Separación coherente entre los grupos objetivo: Dataset 1 (Cítricos / Tropicales / Carozo) y Dataset 2 (Premium / Comercial / Descarte).
- Comportamiento del sistema ante distintos valores de ρ (análisis de sensibilidad).

El parámetro ρ se documentará explícitamente en cada corrida del informe final para permitir la reproducibilidad de los resultados.

4. Roles del Equipo

El desarrollo del proyecto es **colaborativo**: todos los integrantes participan en la comprensión general del sistema para garantizar que nadie entregue una parte sin entender el todo. Los roles indican responsabilidad principal, no exclusividad.

Integrante	Rol Principal	Responsabilidad
Barbera Mateo	Arquitectura	Diseño de la estructura lógica de la red ART1 y del flujo de procesamiento de datos.
Carballo Tobías	Testing	Diseño y ejecución de pruebas funcionales. Validación de las corridas con ambos datasets.

Dacuy Santino	Líder / Arquitectura de código	Coordinación general del proyecto. Referente técnico durante el desarrollo del código CarGross.py.
Etchegoyen Nicolás	Repositorio	Configuración y mantenimiento del repositorio de código. Control de versiones y organización de archivos.
Leiva Osvaldo	Documentación	Redacción del manual de referencia, FAQ, informe final y carátulas.

5. Documentación Preliminar

Se planifica la entrega de los siguientes documentos al cierre del TFI:

Documento	Descripción	Responsable principal
CarGross.py	Código Python autodocumentado de la red ART1. Entrada por CSV, manejo de errores, manejo ante corridas infructuosas.	Dacuy / Barbera
dataset_morfologia.csv	Dataset 1 — Clasificación morfológica de variedades (≥ 50 registros, 5 variables binarias).	Carballo / Etchegoyen
dataset_calidad.csv	Dataset 2 — Control de calidad de manzanas (≥ 50 registros, 5 variables binarias).	Carballo / Etchegoyen
manual_referencia.pdf	Instalación, alcances, limitaciones, test demo, FAQ (mín. 3 preguntas), referencias bibliográficas.	Leiva
informe_corridas.pdf	Evaluación de resultados de ambas corridas con análisis de clústeres generados.	Leiva / Carballo
PPT con sonido	Presentación con origen, justificación, características ART1, fortalezas, debilidades y comparación con otras redes.	Grupal

Referencias Bibliográficas

[1] Sánchez-Sinencio, E. & Lau, C. (1992). *Artificial Neural Networks*. IEEE Press.
(Material provisto como *Lau.pp 5.a.11.pdf* y *Lau.pp 12.a.14.pdf*)