



TRABAJO PRÁCTICO INTEGRADOR
Data Warehouse y Business Intelligence

INTEGRANTES

Carballo Tobías

Dacuy Santino

CÁTEDRA

Base de Datos Avanzada

EQUIPO DOCENTE

Esp. Lic. Escalante Julián

Lic. Pablo Pescio

FECHA

09/08/2026

CAPÍTULO 1 - Introducción

1.1 Introducción y Objetivo General

Hoy en día, las organizaciones generan grandes volúmenes de información. Sin embargo, disponer de datos no garantiza la obtención de conocimiento útil para la toma de decisiones. Por eso es necesario integrar, organizar y analizar la información mediante herramientas de Business Intelligence (BI) y Data Warehouse (DWH). En este contexto, Retail Vision, una empresa del sector retail, enfrenta el desafío de consolidar la información generada por sus diferentes áreas. El crecimiento sostenido de la empresa ha provocado que los datos se encuentren distribuidos en muchos sistemas, dificultando el análisis integral del negocio. El presente trabajo tiene como finalidad diseñar e implementar un Data Warehouse que permita integrar la información proveniente de distintas fuentes, facilitando la construcción de indicadores estratégicos y dashboards interactivos mediante Tableau. En particular, el proyecto se enfoca en la Línea 2: Experiencia del Cliente y Fidelización, buscando comprender el comportamiento de los clientes, medir su satisfacción y detectar oportunidades de mejora que contribuyan a fortalecer la relación entre la empresa y sus consumidores.

1.2 Objetivos Específicos

- Analizar las fuentes de datos disponibles.
- Diseñar un modelo dimensional adecuado para el análisis.
- Implementar un proceso ETL reproducible.
- Integrar la información proveniente de múltiples archivos.
- Construir dashboards interactivos utilizando Tableau.
- Desarrollar indicadores (KPIs) relacionados con la experiencia del cliente y la fidelización.
- Responder las preguntas de negocio planteadas por la cátedra.

CAPÍTULO 2 - Descripción de la problemática

2.1 Contexto

Retail Vision es una empresa dedicada al comercio minorista que opera mediante sucursales físicas y canales digitales. Durante los últimos años experimentó un importante crecimiento tanto en la cantidad de clientes como en el volumen de ventas y la diversidad de productos comercializados. Este crecimiento permitió ampliar la presencia de la empresa en distintas regiones, pero también generó nuevos desafíos relacionados con la integración y explotación de la información.

2.2 Problemática

Actualmente la organización dispone de información distribuida en distintos sistemas operacionales correspondientes a ventas, clientes, productos, inventario, campañas comerciales, devoluciones y satisfacción del cliente. La falta de integración entre estas fuentes dificulta la obtención de indicadores confiables, impidiendo responder de manera rápida y precisa preguntas estratégicas relacionadas con el comportamiento de los clientes y la calidad del servicio ofrecido. Como consecuencia, la empresa encuentra limitaciones para diseñar estrategias de fidelización, identificar oportunidades de mejora y evaluar el impacto de las decisiones comerciales.

2.3 Justificación del proyecto

La implementación de un Data Warehouse permitirá centralizar la información proveniente de diferentes áreas de la empresa, garantizando consistencia, calidad y disponibilidad de los datos para su posterior análisis. A partir de esto será posible construir dashboards interactivos mediante Tableau, facilitando la visualización de indicadores clave de desempeño (KPIs) y proporcionando información relevante para la toma de decisiones basada en datos.

CAPÍTULO 3 – Relevamiento y Diccionario de Datos

3.1 Fuentes de datos disponibles

El conjunto de datos provisto por la cátedra (Kaggle, dataset «Retail Vision») está compuesto por 14 archivos CSV. Se relevaron todas las fuentes, dado que varias dimensiones (Cliente, Producto, Tienda) son compartidas por las cuatro líneas de análisis, solo utilizaremos las necesarias para nuestro caso “Línea 2”.

Archivo	Filas	Rol
Clientes.csv	1.000	Dimensión Cliente
Vendas.csv	20.000	Hecho Ventas (fuente A)
Avaliacoes.csv	10.000	Valoraciones de producto (sin Cliente_ID)
Satisfacao.csv	1.000	Encuestas de satisfacción por cliente
Devolucoes.csv	1.000	Devoluciones, vinculadas a Producto y Cliente
Produtos.csv	1.000	Dimensión Producto (soporte)
Lojas.csv	5	Dimensión Tienda (soporte)
Campanhas.csv	2.000	Campañas de marketing (soporte / canal)
Colaboradores.csv, Custos_Operacionais.csv, Fornecedores.csv, Pedidos_Compra.csv, Stock.csv	-	Fuera de foco (Líneas 3 y 4)

3.2 Diccionario de datos — fuentes de la Línea 2

Clientes.csv

Campo	Descripción
Cliente_ID	Identificador único del cliente
Nome	Nombre completo
Idade	Edad del cliente
Género	Género
Cidade	Ciudad de residencia
Canal de Compra	Canal preferido (Online/Física)
Total de Compras	Monto acumulado histórico de compras

Vendas.csv / Historico_Vendas.csv (misma estructura)

Campo	Descripción
Venda_ID	ID de venta (no único entre ambos archivos)
Loja_ID / Produto_ID / Cliente_ID / Colaborador_ID	Claves foráneas
Quantidade	Unidades vendidas
Preço Unitário	Precio unitario en esa venta
Data da Venda	Fecha de la transacción
Canal de Venda	Física / Online

Avaliaco.es.csv

Campo	Descripción
Produto_ID	FK a Productos
Avaliação	Puntaje de la reseña
Comentário	Comentario libre

Satisfacao.csv

Campo	Descripción
Cliente_ID	FK a Clientes
Inquérito_ID	ID de la encuesta
Pontuação	Puntaje de satisfacción
Data do Inquérito	Fecha de la encuesta

Devolucoes.csv

Campo	Descripción
Devolução_ID	Identificador único
Venda_ID	Referencia informativa (no se resuelve a la fuente)
Produto_ID / Cliente_ID	FK directas a Producto y Cliente
Quantidade	Unidades devueltas
Motivo da Devolução	Motivo categorizado
Data da Devolução	Fecha de la devolución

Capítulo 4 – Diseño del modelo dimensional

4.1 Enfoque de modelado

Adoptamos un esquema en estrella, apropiado para el volumen y la complejidad de las fuentes relevadas, y por ser el formato de mejor rendimiento y más simple de interpretar al conectarse desde Tableau. Cada tabla de hechos representa un proceso de negocio de la Línea 2 (ventas, satisfacción, devoluciones, valoraciones) y se vincula a dimensiones compartidas (Cliente, Producto, Tienda, Tiempo).


4.2 Tablas de hechos

Tabla de hechos	Granularidad	Métricas principales
Fact_Ventas	Una fila por línea de venta procesada	Cantidad, Precio_Unitario, Monto_Total
Fact_Satisfaccion	Una fila por encuesta respondida	Puntuacion
Fact_Devolucion	Una fila por devolución	Cantidad, Motivo
Fact_Valoracion	Una fila por reseña de producto	Puntuacion

4.3 Dimensiones

Dimensión	Atributos clave	Atributos derivados
Dim_Cliente	Nombre, Edad, Genero, Ciudad, Canal_Compra_Preferido	Segmento_Edad, Segmento_Valor
Dim_Producto	Nombre, Categoria, Color, Precio	Margen_Unitario
Dim_Tienda	Nombre, Region, Ciudad, Tipo	—
Dim_Tiempo	Fecha, Anio, Mes, Dia_Semana	Trimestre, Mes_Nombre

4.4 Esquema en estrella



Capítulo 5 – Proceso ETL

5.1 Extracción

A partir del análisis del catálogo de 14 fuentes originales en formato CSV, se seleccionaron las 6 tablas específicas para la Línea 2 (Experiencia del Cliente y Fidelización): Clientes.csv, Produtos.csv, Vendas.csv, Devolucoes.csv, Avaliaco.es.csv y Satisfacao.csv.

Debido a que los archivos fuente presentaban diferencia de formatos (encabezados con estilo Markdown, líneas y caracteres), se desarrolló un script en Python (convertir_csv.py). Este script automatiza la remoción del marcado Markdown, limpia espacios y genera archivos CSV planos normalizados (limpio_X.csv).

5.2 Transformación

Los archivos limpios se cargaron masivamente mediante el comando COPY a una capa de Staging (stg_*) en PostgreSQL, donde se aplicaron las siguientes reglas de negocio y transformaciones analíticas mediante SQL DML:

- Normalización de identificadores y nombres de campos: Mapeo de atributos de portugués a español y tratamiento de nombres con caracteres especiales.
- Casting y tipado estricto: Conversión de campos de texto (TEXT) a tipos de datos analíticos (INT, NUMERIC, DATE).
- Generación de claves sustitutas (_sk): Creación de claves primarias numéricas autoincrementales (SERIAL PRIMARY KEY) en todas las dimensiones (cliente_sk,

producto_sk, canal_sk, tiempo_sk) para independizar el DWH del esquema operacional.

- Segmentación de clientes: Cálculo de la métrica derivada segmento_valor en dim_cliente clasificando la cartera en Alto Valor, Medio Valor y Bajo Valor según sus umbrales históricos de compras.
- Tipificación de Canales: Clasificación del atributo tipo_canal en dim_canal (Online vs. Presencial) a partir del canal de origen.
- Construcción de la Dimensión Tiempo: Generación explícita de dim_tiempo extrayendo año, trimestre, mes, día y día de la semana a partir de las fechas de las transacciones.

5.3 Carga

Las transformaciones poblaron el Data Warehouse dentro de PostgreSQL, con el nombre “dwh_experiencia_cliente”.

El esquema cargado tiene 4 dimensiones (dim_cliente, dim_producto, dim_canal, dim_tiempo) y 3 tablas de hechos (fact_ventas, fact_devoluciones, fact_satisfaccion). Esta base de datos servirá como fuente de conexión directa a Tableau mediante el conector nativo de PostgreSQL (puerto 5432).

5.4 Reproducibilidad

El proceso es 100% reproducible de la siguiente manera:

1. Ante el ingreso de nuevas actualizaciones o archivos crudos del sistema, se ejecuta el script de python (convertir_csv.py) para generar las estructuras limpias.
2. Luego, mediante los scripts desarrollados en SQL, la capa de Staging se refresca y re-puebla automáticamente el Data Warehouse en PostgreSQL sin pérdida de integridad referencial ni duplicación de registros.

5.5 Código SQL

Definición de Estructuras (DDL)

```
-- =====
-- 1. CAPA DE STAGING (Tablas temporales para recibir CSVs)
-- =====
DROP TABLE IF EXISTS stg_clientes, stg_productos, stg_ventas, stg_devoluciones,
stg_evaluaciones, stg_satisfaccion CASCADE;

CREATE TABLE stg_clientes (
    cliente_id TEXT, nome TEXT, idade TEXT, genero TEXT,
    cidade TEXT, canal_de_compra TEXT, total_de_compras TEXT, imagem TEXT
);

CREATE TABLE stg_productos (
```

```
    produto_id TEXT, nome TEXT, categoria TEXT, cor TEXT,  
    descricao TEXT, tamanho TEXT, preco TEXT, custo_aquisicao TEXT, imagem TEXT  
);
```

```
CREATE TABLE stg_ventas (  
    venda_id TEXT,  
    loja_id TEXT,  
    produto_id TEXT,  
    cliente_id TEXT,  
    colaborador_id TEXT,  
    quantidade TEXT,  
    preco_unitario TEXT,  
    data_venda TEXT,  
    canal_venda TEXT  
);
```

```
CREATE TABLE stg_devoluciones (  
    devolucao_id TEXT, venda_id TEXT, produto_id TEXT, cliente_id TEXT,  
    quantidade TEXT, motivo TEXT, data_devolucao TEXT  
);
```

```
CREATE TABLE stg_evaluaciones (  
    produto_id TEXT, avaliacao TEXT, comentario TEXT  
);
```

```
CREATE TABLE stg_satisfaccion (  
    cliente_id TEXT, inquerito_id TEXT, pontuacao TEXT, comentario TEXT, data_inquerito  
    TEXT  
);
```

```
-- =====  
-- 2. CAPA DEL DATA WAREHOUSE DEFINITIVO (Esquema Estrella)  
-- =====
```

```
CREATE TABLE dim_cliente (  
    cliente_sk SERIAL PRIMARY KEY,  
    cliente_id INT UNIQUE,  
    nombre_cliente VARCHAR(150),  
    genero VARCHAR(20),  
    edad INT,  
    ciudad VARCHAR(100),  
    segmento_valor VARCHAR(50)  
);
```

```
CREATE TABLE dim_producto (  
    producto_sk SERIAL PRIMARY KEY,  
    producto_id INT UNIQUE,  
    nombre_producto VARCHAR(150),
```



```
    categoria VARCHAR(100),  
    precio_lista NUMERIC  
);
```

```
CREATE TABLE dim_canal (  
    canal_sk SERIAL PRIMARY KEY,  
    nombre_canal VARCHAR(50) UNIQUE,  
    tipo_canal VARCHAR(20)  
);
```

```
CREATE TABLE dim_tiempo (  
    tiempo_sk SERIAL PRIMARY KEY,  
    fecha_completa DATE UNIQUE,  
    anio INT,  
    trimestre INT,  
    mes INT,  
    dia INT,  
    dia_semana VARCHAR(20)  
);
```

```
CREATE TABLE fact_ventas (  
    venta_id INT,  
    cliente_sk INT REFERENCES dim_cliente(cliente_sk),  
    producto_sk INT REFERENCES dim_producto(producto_sk),  
    canal_sk INT REFERENCES dim_canal(canal_sk),  
    tiempo_sk INT REFERENCES dim_tiempo(tiempo_sk),  
    metodo_pago VARCHAR(50),  
    cantidad_vendida INT,  
    monto_total_venta NUMERIC  
);
```

```
CREATE TABLE fact_devoluciones (  
    devolucion_id INT,  
    cliente_sk INT REFERENCES dim_cliente(cliente_sk),  
    producto_sk INT REFERENCES dim_producto(producto_sk),  
    tiempo_sk INT REFERENCES dim_tiempo(tiempo_sk),  
    cantidad_devuelta INT,  
    motivo VARCHAR(150)  
);
```

```
CREATE TABLE fact_satisfaccion (  
    cliente_sk INT REFERENCES dim_cliente(cliente_sk),  
    producto_sk INT REFERENCES dim_producto(producto_sk),  
    tiempo_sk INT REFERENCES dim_tiempo(tiempo_sk),  
    puntuacion_encuesta INT,  
    calificacion_producto NUMERIC(4,2)  
);
```

Carga Masiva a Staging (DML) - ejemplo

-- Ejemplo de ingesta directa por SQL del archivo limpio

COPY stg_ventas (venda_id, loja_id, produto_id, cliente_id, colaborador_id, quantidade, preco_unitario, data_venda, canal_venda)

FROM 'C:/temp/limpio_Vendas.csv'

WITH (

 FORMAT csv,

 HEADER true,

 DELIMITER ',',

 QUOTE '"',

 ENCODING 'UTF8'

);

Transformación y Poblamiento

-- 1. Poblar DIM_CLIENTE

INSERT INTO dim_cliente (cliente_id, nombre_cliente, genero, edad, ciudad, segmento_valor)

SELECT DISTINCT

 CAST(cliente_id AS INT),

 nome,

 genero,

 CAST(idade AS INT),

 cidade,

 CASE

 WHEN CAST(total_de_compras AS NUMERIC) > 5000 THEN 'Alto Valor'

 WHEN CAST(total_de_compras AS NUMERIC) BETWEEN 2000 AND 5000 THEN
'Medio Valor'

 ELSE 'Bajo Valor'

END

FROM stg_clientes

WHERE cliente_id IS NOT NULL AND cliente_id != 'Cliente_ID'

ON CONFLICT (cliente_id) DO NOTHING;

-- 2. Poblar DIM_PRODUCTO

INSERT INTO dim_producto (producto_id, nombre_producto, categoria, precio_lista)

SELECT DISTINCT

CAST(producto_id AS INT),

nome,

categoria,

CAST(preco AS NUMERIC)

FROM stg_productos

WHERE produto_id IS NOT NULL AND produto_id != 'Produto_ID'

ON CONFLICT (producto_id) DO NOTHING;

-- 3. Poblar DIM_CANAL

INSERT INTO dim_canal (nombre_canal, tipo_canal)

SELECT DISTINCT

canal_venta,

CASE WHEN LOWER(canal_venta) LIKE '%online%' OR LOWER(canal_venta) LIKE '%app%' THEN 'Online' ELSE 'Presencial' END

FROM stg_ventas

WHERE canal_venta IS NOT NULL AND canal_venta != 'Canal_Venda' AND canal_venta != 'Canal de Venda'

ON CONFLICT (nombre_canal) DO NOTHING;

-- 4. Poblar DIM_TIEMPO

INSERT INTO dim_tiempo (fecha_completa, anio, trimestre, mes, dia, dia_semana)

SELECT DISTINCT

CAST(data_venta AS DATE),

EXTRACT(YEAR FROM CAST(data_venta AS DATE)),

EXTRACT(QUARTER FROM CAST(data_venta AS DATE)),

EXTRACT(MONTH FROM CAST(data_venta AS DATE)),

EXTRACT(DAY FROM CAST(data_venta AS DATE)),

TO_CHAR(CAST(data_venta AS DATE), 'Day')

FROM stg_ventas

WHERE data_venta IS NOT NULL AND data_venta != 'Data_Venda' AND data_venta !=
'Data da Venda'

ON CONFLICT (fecha_completa) DO NOTHING;

-- 5. Poblar FACT_VENTAS

INSERT INTO fact_ventas (venta_id, cliente_sk, producto_sk, canal_sk, tiempo_sk,
cantidad_vendida, monto_total_venta)

SELECT

CAST(v.venta_id AS INT),

c.cliente_sk,

p.producto_sk,

cn.canal_sk,

tm.tiempo_sk,

CAST(v.quantidade AS INT),

CAST(v.quantidade AS NUMERIC) * CAST(v.preco_unitario AS NUMERIC)

FROM stg_ventas v

JOIN dim_cliente c ON CAST(v.cliente_id AS INT) = c.cliente_id

JOIN dim_producto p ON CAST(v.produto_id AS INT) = p.producto_id

JOIN dim_canal cn ON v.canal_venta = cn.nombre_canal

JOIN dim_tiempo tm ON CAST(v.data_venta AS DATE) = tm.fecha_completa;

-- 6. Poblar FACT_DEVOLUCIONES

INSERT INTO fact_devoluciones (devolucion_id, cliente_sk, producto_sk, tiempo_sk, cantidad_devuelta, motivo)

SELECT

CAST(d.devolucao_id AS INT),

c.cliente_sk,

p.producto_sk,

tm.tiempo_sk,

CAST(d.quantidade AS INT),

d.motivo

FROM stg_devoluciones d

JOIN dim_cliente c ON CAST(d.cliente_id AS INT) = c.cliente_id

JOIN dim_producto p ON CAST(d.produto_id AS INT) = p.producto_id

JOIN dim_tiempo tm ON CAST(d.data_devolucao AS DATE) = tm.fecha_completa;

-- 7. Poblar FACT_SATISFACCION

INSERT INTO fact_satisfaccion (cliente_sk, producto_sk, tiempo_sk, puntuacion_encuesta, calificacion_producto)

SELECT

c.cliente_sk,

p.producto_sk,

tm.tiempo_sk,

CAST(s.pontuacao AS INT),

CAST(ev.avaliacao AS NUMERIC(4,2))

FROM stg_satisfaccion s

JOIN dim_cliente c ON CAST(s.cliente_id AS INT) = c.cliente_id

JOIN dim_tiempo tm ON CAST(s.data_inquerito AS DATE) = tm.fecha_completa

CROSS JOIN dim_producto p

LEFT JOIN stg_evaluaciones ev ON p.producto_id = CAST(ev.produto_id AS INT);

Capítulo 6 – Indicadores (KPIs) y preguntas de negocio

A continuación se presenta la Línea 2 (Experiencia del Cliente y Fidelización). Se detallan las preguntas de negocio clave planteadas por la cátedra, junto con los Indicadores Clave de Desempeño (KPIs), fórmulas analíticas de cálculo y tablas del Data Warehouse involucradas en PostgreSQL.

Pregunta de negocio	KPI	Cálculo / fuente
¿Qué perfiles de clientes generan mayor valor?	Valor total de compra por segmento	SUM(fact_ventas.monto_total_venta) agrupado por dim_cliente.segmento_valor, edad y genero.
¿Qué características tienen los clientes con mayor frecuencia de compra?	Frecuencia de compra por cliente	COUNT(fact_ventas.venta_id) / COUNT(DISTINCT dim_cliente.cliente_sk) agrupado por segmento de cliente.
¿Relación entre valoraciones y devoluciones?	Valoración promedio vs. tasa de devolución por producto	AVG(fact_satisfaccion.calificacion_producto) vs. (COUNT(fact_devoluciones.devoluciones_id) / COUNT(fact_ventas.venta_id)) por dim_producto.producto_id.
¿Qué categorías generan mayor satisfacción/insatisfacción?	Puntaje de Satisfacción Promedio por Categoría	AVG(fact_satisfaccion.puntuacion_en_cuesta) agrupado por dim_producto.categoria.
¿Qué segmentos tienen mayor propensión a devolver?	Tasa de devolución por segmento	COUNT(fact_devoluciones.devoluciones_id) / COUNT(fact_ventas.venta_id) agrupado por dim_cliente.segmento_valor.
¿Cómo varía el comportamiento entre canales?	Monto Total y Volumen de Ventas por Canal	SUM(fact_ventas.monto_total_venta) y COUNT(fact_ventas.venta_id) agrupado por dim_canal.nombre_canal (Online vs. Presencial).

Capítulo 7 – Dashboards en Tableau

7.1 Conexión a los datos


Se estableció la conexión directa Tableau Desktop hacia el motor PostgreSQL, apuntando al servidor localhost (puerto 5432) y la base de datos dwh_experiencia_cliente.

En la capa de modelado de datos de Tableau, se configuró la tabla central de hechos fact_ventas vinculada lógicamente con las dimensiones conformadas dim_cliente, dim_producto, dim_canal y dim_tiempo mediante sus claves sustitutas (cliente_sk, producto_sk, canal_sk, tiempo_sk). Este esquema en estrella previene la duplicación de filas y optimiza el rendimiento OLAP.


7.2 Hojas construidas (una por KPI)

Para responder cada KPI de la Línea 2, se construyeron las siguientes hojas de trabajo individuales en Tableau Desktop:


- **Ventas por Canal (Online vs. Presencial):**




- **Valor por Segmento de Cliente:**




● Frecuencia de Compra por Cliente:




● Satisfacción Promedio por Categoría de Producto:



- **Tasa de Devolución por Segmento de Cliente:**




- **Relación Valoración vs. Tasa de Devolución por Producto:**



7.3 Dashboard final

Las seis hojas analíticas se integraron en un Dashboard interactivo. El tablero cuenta con un panel superior de Filtros Globales Interactivos que aplican dinámicamente sobre todas las hojas de trabajo:

1. **Filtro Temporal:** dim_tiempo.anio (Filtro por año de análisis).
2. **Filtro Categoría:** dim_producto.categoria (Filtro por familia de productos).
3. **Filtro Canal:** dim_canal.tipo_canal (Online vs. Presencial).



Conclusión

El desarrollo del proyecto permitió diseñar, transformar e implementar con éxito un Data Warehouse relacional orientado a la Línea 2 (Experiencia del Cliente y Fidelización) en PostgreSQL, integrando y normalizando información previamente dispersa en fuentes heterogéneas en bruto. Entre los principales desafíos técnicos resueltos destacaron la remoción automatizada de variación de caracteres mediante scripts de Python. La estrategia de modelado dimensional en estrella (Star Schema) garantizó la integridad referencial y eliminó la duplicación de filas al trabajar con hechos de diferente granularidad. Asimismo, se identificaron limitaciones estructurales a las fuentes originales, las cuales fueron mitigadas en Tableau, usando fuentes de datos, mediante relaciones lógicas sobre las dimensiones compartidas. El modelo dimensional final, junto con los tableros interactivos desarrollados en Tableau, responde de manera directa a las preguntas de negocio planteadas.